



Módulo 04. Visualización y Business Intelligence

Jueves Asincrónico


Estudiante: Frenny Montezuma Castillo

Grupo 04

Entrega: 27 – 08 – 26

1. Lista de errores encontrados y corrección aplicada

Tipo de error	Columna afectada	Registros afectados	Corrección aplicada en Power Query
Filas totalmente duplicadas	Todas las columnas	26 filas idénticas repetidas por completo	Se eliminaron las filas duplicadas exactas, dejando un solo registro por venta (paso Filas Duplicadas Exactas_Eliminadas). Duplicados quitados
Folios de venta (ID_Venta) repetidos	ID_Venta	50 números de folio se repiten en 100 filas; algunas con datos de ventas distintos	Se agregó la columna ID_Venta_Duplicado = VERDADERO/FALSO para que el equipo de ventas confirme cuál folio es el correcto antes de asignar uno nuevo.
Formato de texto inconsistente (mayúsculas y espacios)	Ciudad	37 formas distintas de escribir 15 ciudades reales (ej. "SAN JOSÉ", "san josé", " San José ")	Se recortaron los espacios sobrantes y se unificó el formato a "Primera Letra Mayúscula" en todas las ciudades.
Categorías de producto no estandarizadas	Categoria_Producto	43 variantes distintas para solo 10 categorías reales (abreviaturas como "Herram. de Jardín", "Maceteria", "Sustratos/Tierra", mezcla de mayúsculas/minúsculas)	Se creó una función que reconoce palabras clave y agrupa cada variante bajo su categoría oficial (10 categorías finales).
Nombres de vendedores mal escritos	Vendedor	35 variantes para solo 10 vendedores reales; incluye errores de digitación ("Ana Bindas", "Anna Vindas", "Carla Rojas", "Luiz Gómez", "Marcos Solano")	Se corrigieron los errores de digitación y se unificó el formato de nombre y apellido.

			 
Cantidad guardada como texto	Cantidad	18 filas con valores como "7 unidades" en lugar de un número	Se eliminó la palabra "unidades" y se convirtió la columna completa a tipo numérico.
Cantidades negativas	Cantidad	18 filas con valores negativos (ej. -10 unidades)	Se marcaron con Cantidad_Revisar = VERDADERO por ser físicamente imposibles; quedan pendientes de validar con el punto de venta.
Cantidades con códigos de error (0, 5000, 9999)	Cantidad	17 filas (7 en cero y 10 con 5000 o 9999, cifras típicas de "placeholder" en cajas registradoras)	Se marcaron con Cantidad_Revisar = VERDADERO por estar muy fuera del rango normal de venta (1 a 25 unidades).
Precio unitario con símbolo de moneda y como texto	Precio_Unitario	18 filas con el símbolo "₡" (ej. "₡1255.65"), guardadas como texto	Se eliminó el símbolo ₡ y se convirtió la columna completa a tipo numérico.
Formatos de fecha múltiples e inconsistentes	Fecha_Venta	71 filas en texto, con formatos mezclados: "01 de March de 2025" (español/inglés), "2025.11.19", "11/01/2024", "05-07-2025", "04-02-25" (año de 2 dígitos), etc.	Reemplazo de caracteres y de Mes de a /0?/, al final filtre las que eran fechas erróneas en null y las filtre para no mostrar las null
Fecha imposible	Fecha_Venta	Al menos 1 fila con "31/02/2025" (febrero nunca tiene 31 días)	No pudo interpretarse: el valor quedó vacío y la fila se marcó con Fecha_Revisar = VERDADERO para corrección manual.

Correo electrónico sin arroba (@)	Email_Cliente	13 filas sin el símbolo @ (ej. "luis.sanchez.jimenez435correo.com")	Se insertó el símbolo @ automáticamente antes de "correo.com".
Correo electrónico con espacio antes de la arroba	Email_Cliente	17 filas con un espacio antes del @ (ej. "ricardo...99 @correo.com")	Se eliminaron todos los espacios en blanco dentro del correo.
Teléfono con formato inconsistente	Telefono	48 filas con longitud distinta a 8 dígitos: con guion (11), con letras insertadas (19), con 10 dígitos o solo 5 dígitos	Se conservaron únicamente los dígitos (se quitaron guiones y letras) y se marcaron con Telefono_Revisar = VERDADERO los que no tienen exactamente 8 dígitos.

2. Resumen: confiabilidad del archivo original

Antes de limpiar la información enviada por el Vivero El Jardín Oriental, el archivo presentaba serios problemas de calidad que impedían utilizarlo de forma directa para tomar decisiones de negocio. De las 3,000 ventas registradas en la lista, aproximadamente una de cada tres contenía al menos un error que afectaba la veracidad de los datos. Entre las fallas más comunes se encontraron 26 filas que eran copias idénticas de otras y 50 números de recibo repetidos, lo cual habría inflado de manera falsa el conteo real de las transacciones. Adicionalmente, los textos como los nombres de ciudades, categorías de productos y vendedores tenían decenas de variantes en su forma de escritura para referirse al mismo dato real. Por ejemplo, el sistema interpretaba "San José" y "SAN JOSÉ" como si fueran dos lugares totalmente distintos, lo que en cualquier reporte o gráfica habría fragmentado las cifras reales de ventas por zona o por personal.

El inconveniente más delicado para la salud financiera del reporte radicaba en las inconsistencias numéricas y en la forma en que se ingresaron las fechas. En 138 ventas el precio total final no coincidía al multiplicar la cantidad de productos por el precio unitario, rompiendo la lógica contable básica. A esto se sumaban 35 registros con cantidades absurdas, como valores negativos, en cero o códigos numéricos extraños que parecían equivocaciones de digitación al momento de cobrar en caja. Para complicar aún más la situación, 71 filas mostraban fechas mezcladas entre español e inglés, con formatos inconsistentes e incluso datos imposibles en el calendario, como un registro marcado el 31 de febrero. Si se intentaban calcular las ganancias totales, proyectar las tendencias del negocio a lo largo del tiempo o comparar el rendimiento entre vendedores sin corregir estos fallos, los resultados finales habrían sido engañosos e incorrectos.

En definitiva, se calcula que la información original tenía apenas entre un 60% y un 65% de confiabilidad, ya que aunque la mayoría de los números base existían, el desorden de formatos y los datos equivocados obligaban a realizar una limpieza profunda antes de armar cualquier informe. Tras aplicar un proceso completo de ordenamiento donde se estandarizaron los textos, se corrigieron los tipos de datos, se recalcularon los montos correctos y se solucionaron las fechas, la base de datos ha quedado totalmente saneada y lista para su análisis seguro. Actualmente el archivo es confiable para consultar cualquier indicador de la empresa, habiendo dejado marcado únicamente un pequeñísimo grupo de registros dudosos, equivalente a menos del 2% del total, para que el personal del vivero los pueda verificar a mano si lo considera necesario.